Especialización en Ciencia de Datos

Actividades

Estudiante: Yoseph Barrera
Profesor(a): Silvia Salinas Ayaviri
Fecha: 6 de marzo de 2026

Proyecto Módulo 6: Predicción del gasto promedio por cliente (AOV)

Objetivo

El objetivo de este proyecto fue construir un modelo de aprendizaje supervisado de **regresión** para predecir el **monto promedio de compra por cliente** (*Average Order Value*, AOV) en un contexto de comercio electrónico. Para ello, se compararon distintos algoritmos de regresión, se aplicó validación cruzada, se optimizaron hiperparámetros y se seleccionó el modelo final en función de su capacidad predictiva.

Datos y preprocesamiento

Se utilizó el dataset *Online Retail*, que contiene transacciones de un comercio electrónico. El conjunto original tenía 541,909 observaciones y 8 variables. Luego del proceso de limpieza, la base quedó en 397,884 registros y 9 variables. La limpieza consistió en eliminar observaciones sin identificador de cliente, excluir cancelaciones (facturas cuyo código comienza con `C`) y filtrar transacciones con cantidades o precios no positivos. Posteriormente, se construyó la variable `LineTotal` como el producto entre cantidad y precio unitario.

A partir de esta base se generó una tabla agregada por factura y luego una tabla agregada por cliente. La variable objetivo se definió como el **AOV**, es decir, el promedio del gasto total por factura para cada cliente. Como variables explicativas se utilizaron el número de facturas, promedios de cantidad comprada, número de líneas por compra, número de productos distintos, precio unitario promedio, país, recencia de compra y antigüedad del cliente.

Metodología

La muestra final a nivel cliente quedó compuesta por 4,338 clientes. Esta base se dividió en entrenamiento y prueba usando una partición **80/20**, obteniendo 3,470 observaciones para entrenamiento y 868 para prueba. Para el preprocesamiento se utilizó imputación por mediana en variables numéricas, imputación por moda en la variable categórica `country`, escalamiento estandarizado para variables numéricas y codificación *one-hot* para la variable categórica.

Los modelos evaluados fueron: **Linear Regression**, **Ridge**, **Lasso**, **KNN Regressor** y **Gradient Boosting Regressor**. La comparación inicial se realizó mediante validación cruzada **K-Fold con 5 particiones**, usando como métricas MAE, RMSE y R^2. Posteriormente, se realizó optimización de hiperparámetros mediante `GridSearchCV` para Ridge, Lasso y KNN. Finalmente, se comparó el desempeño de los mejores modelos en el conjunto de prueba.

Como parte complementaria, se incluyó además una sección conceptual de clasificación usando **KNN Classifier**, transformando el AOV en una variable binaria de alto o bajo gasto según la mediana, con el objetivo de contrastar conceptualmente regresión versus clasificación.

Resultados

Los resultados de validación cruzada muestran que **Gradient Boosting** obtuvo el menor error promedio entre los modelos comparados. En particular, alcanzó un MAE de 118.739 y un RMSE de 732.267. Aunque Lasso y Ridge presentaron valores de R^2 levemente mayores en validación cruzada, su error absoluto y cuadrático fue claramente superior, por lo que Gradient Boosting se mantuvo como el mejor candidato para la etapa final.

Cuadro 1: Resultados promedio en validación cruzada (K=5).

Modelo	MAE (CV)	RMSE (CV)	R^2 (CV)
GradientBoosting	118.739	732.267	0.540
Lasso	155.565	992.285	0.601
Ridge	157.156	994.871	0.601
LinearRegression	158.508	998.571	0.598
KNNRegressor	209.635	1169.641	0.323

En la etapa de optimización, los mejores hiperparámetros encontrados fueron $\alpha = 100$ para Ridge, $\alpha = 1$ para Lasso y $k = 3$ para KNN Regressor. Sin embargo, incluso después del ajuste, el modelo de **Gradient Boosting** continuó mostrando el mejor desempeño en el conjunto de prueba.

Cuadro 2: Resultados en el conjunto de prueba.

Modelo	MAE (test)	RMSE (test)	R^2 (test)
GradientBoosting	87.156	203.870	0.750
BestRidge	116.186	245.023	0.638
BestLasso	116.247	246.075	0.635
BestKNN	184.055	380.879	0.126

El modelo final seleccionado fue **Gradient Boosting**, con un MAE de 87.156, un RMSE de 203.870 y un R^2 de 0.750 en test. Esto indica que el modelo logra explicar aproximadamente el 75 % de la variabilidad del gasto promedio por cliente y ofrece el mejor equilibrio entre precisión y capacidad de generalización entre los modelos evaluados.

Clasificación conceptual

En la sección complementaria de clasificación, se construyó una variable binaria que distingue entre clientes de alto y bajo gasto según la mediana del AOV, y se entrenó un **KNN Classifier**. Este modelo alcanzó una exactitud de 0.690. Si bien este ejercicio fue útil para contrastar ambos enfoques, el problema principal del proyecto corresponde claramente a un problema de **regresión**, ya que el interés central es estimar un valor monetario continuo y no asignar categorías discretas.

Conclusión

En conclusión, el proyecto permitió implementar un pipeline completo de aprendizaje supervisado para un problema de regresión aplicado a e-commerce. Se realizó limpieza, agregación, preprocesamiento,

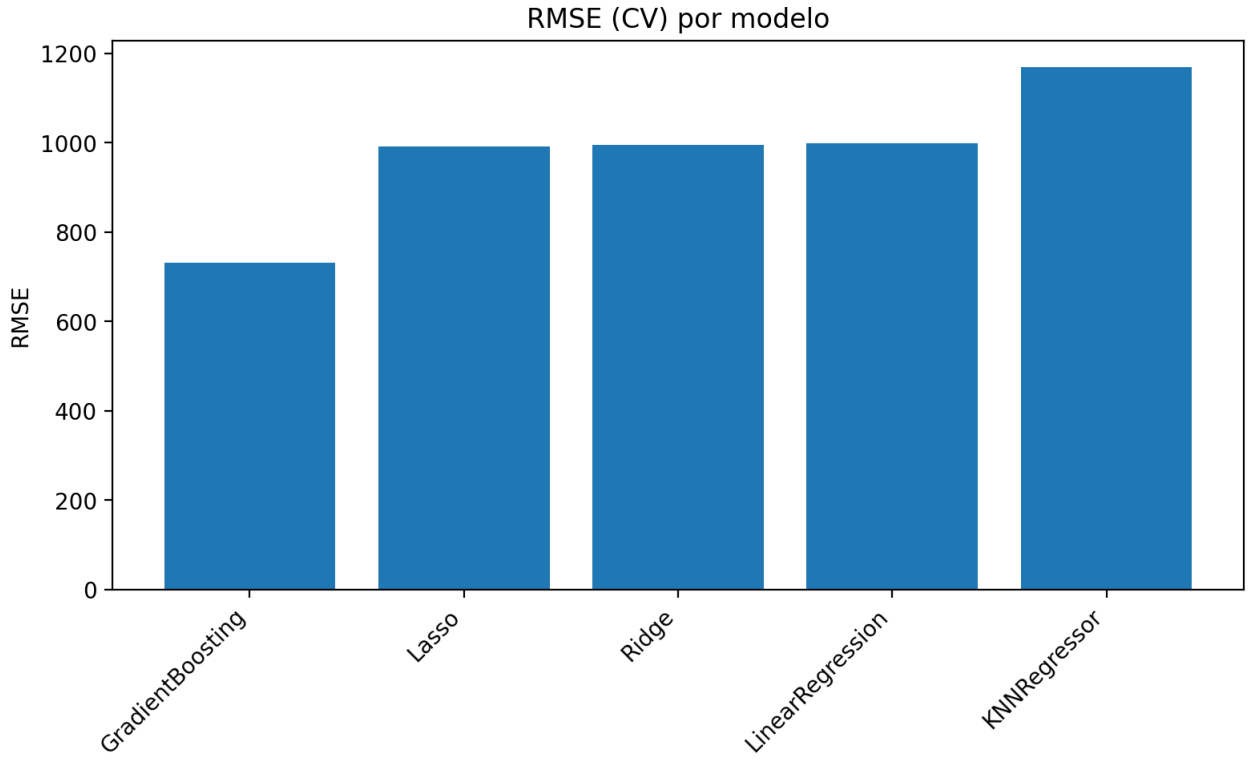

Figura 1: Comparación del RMSE promedio en validación cruzada por modelo.

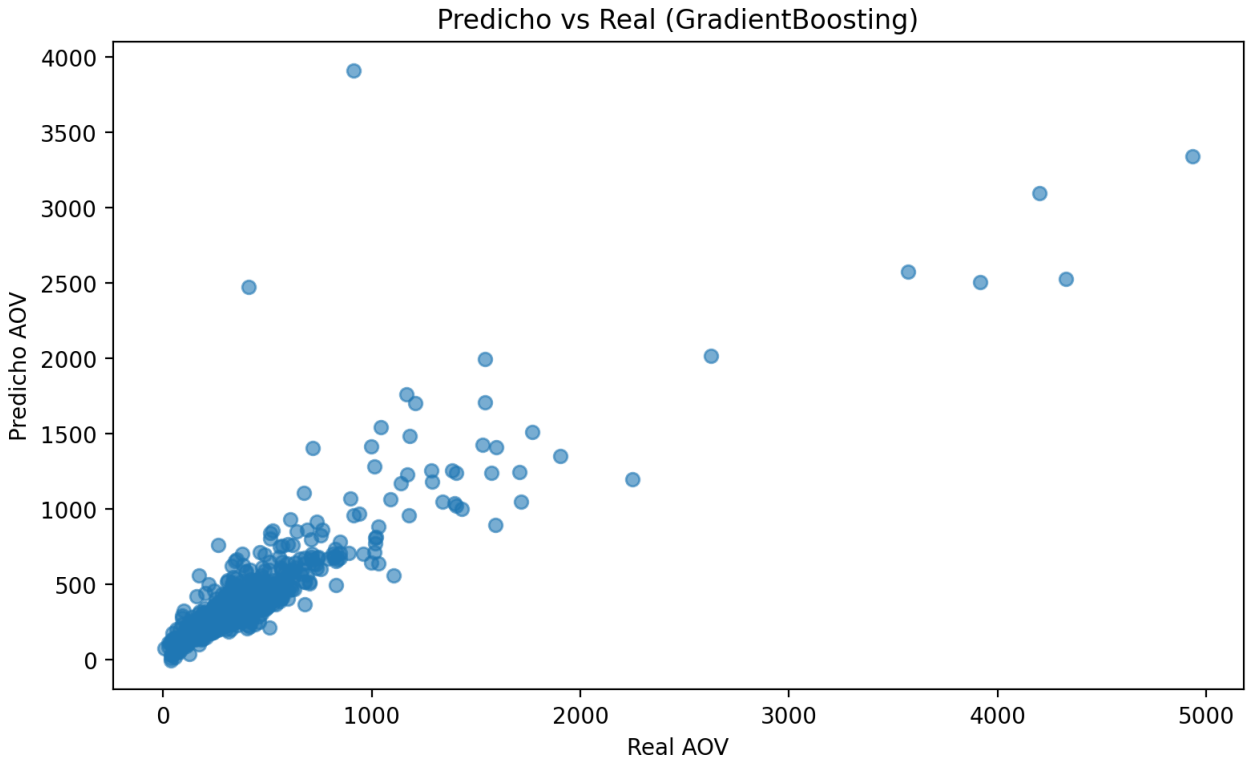

Figura 2: Valores predichos versus reales para el modelo Gradient Boosting en test.

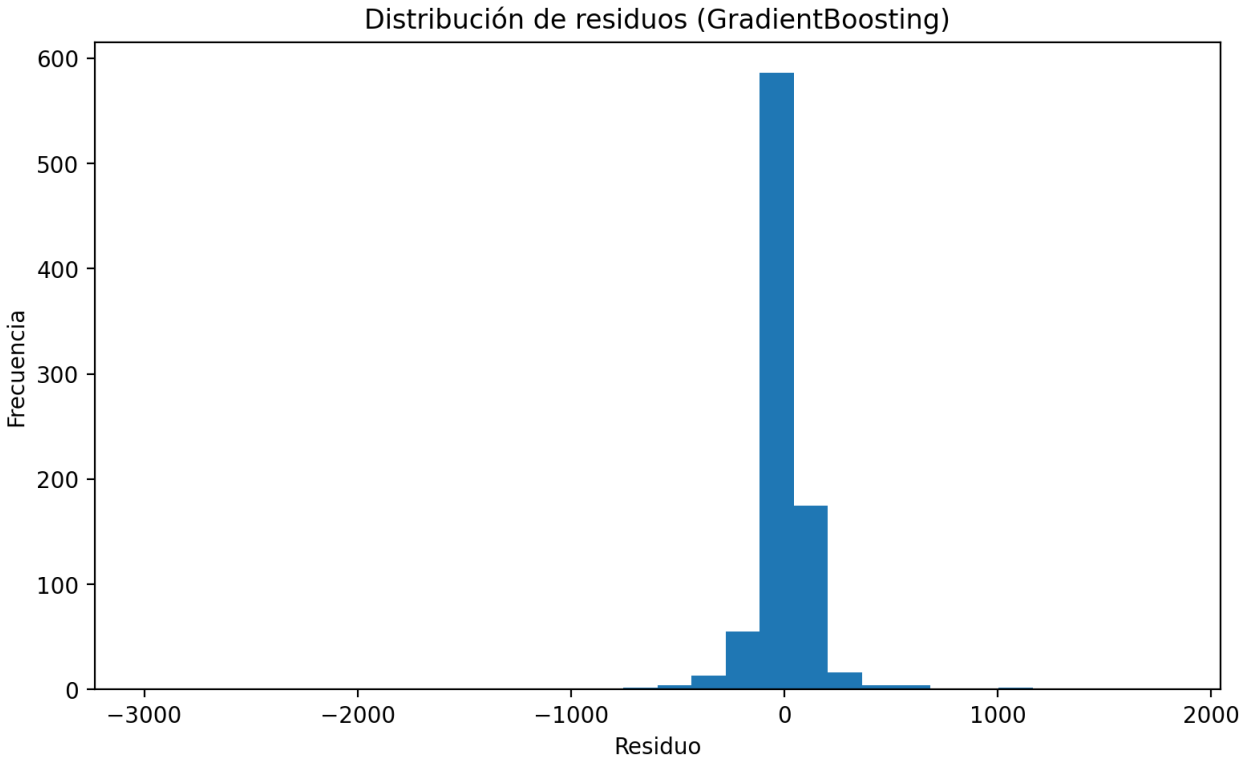

Figura 3: Distribución de residuos del modelo Gradient Boosting.

validación cruzada, comparación de modelos, ajuste de hiperparámetros y evaluación final. Los resultados muestran que **Gradient Boosting** fue el modelo más adecuado para predecir el AOV, superando a los enfoques lineales y a KNN en el conjunto de prueba. Esto sugiere que las relaciones entre las variables del cliente y su gasto promedio presentan patrones no lineales que son mejor capturados por métodos de ensamble.